

АБ Тестирование

Иван Новиков

МФТИ

7 декабря 2024 г.

- 1 Введение
- 2 АБ-тест
- 3 MDE
- 4 Снижение дисперсии
- 5 Метрики

Постановка

Есть две выборки, хотим проверить неравенство нулю разности математических ожиданий между ними

- X_1, \dots, X_n - выборка А (контроль)
- Y_1, \dots, Y_m - выборка В (тест), к ней применяем изменение
- $H_0 : \mathbb{E}X = (\leq, \geq) \mathbb{E}Y$ - эффекта нет
- $H_1 : \mathbb{E}X \neq (>, <) \mathbb{E}Y$ - эффект есть

- 1 Введение
- 2 АБ-тест
- 3 MDE
- 4 Снижение дисперсии
- 5 Метрики

t-test для двух независимых выборок 1

$$X_1, \dots, X_n \sim \mathcal{N}(a_X, \sigma_X^2)$$

$$Y_1, \dots, Y_m \sim \mathcal{N}(a_Y, \sigma_Y^2)$$

Случай 1 (t-test)

$\sigma = \sigma_X = \sigma_Y$ - неизвестны

S_Y^2, S_X^2 - несмещённые оценки дисперсий у Y и X

$$S^2 = \frac{(m-1)S_Y^2 + (n-1)S_X^2}{n+m-2}$$

$$T(X, Y) = \frac{\bar{Y} - \bar{X}}{S \sqrt{\frac{1}{m} + \frac{1}{n}}} \stackrel{H_0}{\sim} T_{n+m-2}$$

t-test для двух независимых выборок 2

$$X_1, \dots, X_n \sim \mathcal{N}(a_X, \sigma_X^2)$$

$$Y_1, \dots, Y_m \sim \mathcal{N}(a_Y, \sigma_Y^2)$$

Случай 2 (Тест Уэлча)

$\sigma_X \neq \sigma_Y$ - неизвестны

S_Y^2, S_X^2 - несмещённые оценки дисперсий у Y и X

$$\nu \approx \frac{\left(\frac{S_Y^2}{m} + \frac{S_X^2}{n}\right)^2}{\frac{S_Y^4}{m^2(m-1)} + \frac{S_X^4}{n^2(n-1)}}$$

$$T(X, Y) = \frac{\bar{Y} - \bar{X}}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \stackrel{H_0}{\sim} T_\nu$$

Общий случай для независимых выборок

Пусть $X_1, \dots, X_n, Y_1, \dots, Y_m$ - независимые выборки

Тогда

$$T(X, Y) = \frac{\bar{Y} - \bar{X}}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \xrightarrow{d_0} \mathcal{N}(0, 1)$$

Общий случай для связанных выборок

Сводим к одновыборочному тесту

$$\delta_i = Y_i - X_i$$

Требование: $\delta_1, \dots, \delta_n$ - выборка, конечная дисперсия

$$H_0 : \mathbb{E}\delta = 0$$

$$H_1 : \mathbb{E}\delta \neq 0$$

$$T(X, Y) = \sqrt{n} \frac{\bar{\delta}}{S_{\delta}} \xrightarrow{d_0} \mathcal{N}(0, 1)$$

Другие тесты

Но что если данные не из $\mathcal{N}(a, \sigma^2)$?

- Если данных много, то можно вспомнить общий случай
- Также можно использовать бутстреп, построить бутстрепированную выборку статистик T , построить доверительный интервал - если 0 не попадает в интервал, то отвергаем H_0
- Если всё же данных мало - смотрим на распределение метрики и исходя из этого делаем тест (Точный тест Фишера, E-test, критерий χ^2 , ...)
- Если даже распределение непонятно, то U-критерий Манна — Уитни

U-критерий Манна-Уитни

- $X_1, \dots, X_n, Y_1, \dots, Y_m$ - независимые выборки, $Z = X_1, \dots, X_n, Y_1, \dots, Y_m$, R_1, \dots, R_{n+m} - ранги
- $F_X(x + \mu) = F_Y(x)$
- $H_0 : \mu = 0, H_1 : \mu \neq 0$

$$R_X = \sum_{i=1}^n R_{X_i}, R_Y = \sum_{i=1}^m R_{Y_i}$$

$$U_X = nm + \frac{n(n+1)}{2} - R_X, U_Y = nm + \frac{m(m+1)}{2} - R_Y$$

$$U = \min\{U_X, U_Y\} \xrightarrow{d} \mathcal{N}\left(\frac{nm}{2}, \frac{nm(n+m+1)}{12}\right)$$

AA-test

Можно провалидировать тест

- В онлайн

Чаще всего берут 2 группы без изменений и делают несколько раз тест, проверяют что тест не детектирует эффект

- В офлайне

Берём исторические данные и делаем много раз тест, получаем выборку отвержений и неотвержений a_1, \dots, a_n (например бутстрепом), проверяем $H_0 : \mathbb{E}a \leq \alpha$

Метод бакетов

Иногда у данных есть проблемы:

- Слишком много данных
- Зависимые данные (а то есть не являются выборкой) - например сессии пользователей

Метод бакетов

B - количество бакетов

$$\text{bucket_id}(\text{user_id}) = \text{hash}(\text{user_id}) \% B$$

$$Y_i = \text{mean}(\{X_{\text{user_id}} | \text{bucket_id}(\text{user_id}) = i\})$$

Получаем Y_1, Y_2, \dots, Y_B - выборка бакетов

- 1 Введение
- 2 АБ-тест
- 3 MDE**
- 4 Снижение дисперсии
- 5 Метрики

Ошибки




Рис. 1: Ошибки

MDE

Theorem (MDE)

- 1 $X_1, \dots, X_n, Y_1, \dots, Y_m$ - независимые выборки
- 2 α - уровень значимости критерия
- 3 $1 - \beta$ - мощность критерия
- 4 e - эффект
- 5 $H_0 : \mathbb{E}Y \leq \mathbb{E}X$ и $H_1 : \mathbb{E}Y > \mathbb{E}X$ при односторонней альтернативе
- 6 $H_0 : \mathbb{E}Y = \mathbb{E}X$ и $H_1 : \mathbb{E}Y \neq \mathbb{E}X$ при двусторонней альтернативе

Тогда

- 1 при односторонней альтернативе $e \geq (z_{1-\alpha} + z_{1-\beta}) \sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}$
- 2 при двусторонней альтернативе $e \geq (z_{1-\frac{\alpha}{2}} + z_{1-\beta}) \sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}$

MDE

Доказательство (MDE)

$$P_0 \left(\frac{\bar{Y} - \bar{X}}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} > z_{1-\alpha} \right) \leq \alpha, \quad P_e \left(\frac{\bar{Y} - \bar{X}}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} > z_{1-\alpha} \right) \geq 1 - \beta$$

$$P_e \left(\frac{\bar{Y} - \bar{X}}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} > z_{1-\alpha} \right) = P_e \left(\frac{\bar{Y} - \bar{X} - e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} > z_{1-\alpha} - \frac{e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \right)$$

$$\frac{(\bar{Y} - \bar{X}) - e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \xrightarrow{d_e} \mathcal{N}(0, 1) \Rightarrow P_e \left(\frac{\bar{Y} - \bar{X}}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} > z_{1-\alpha} \right) \rightarrow 1 - \Phi \left(z_{1-\alpha} - \frac{e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \right)$$

MDE

Доказательство (MDE)

$$1 - \Phi \left(z_{1-\alpha} - \frac{e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \right) \geq 1 - \beta \Rightarrow \Phi \left(z_{1-\alpha} - \frac{e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \right) \leq \beta$$

$$z_{1-\alpha} - \frac{e}{\sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}} \leq \Phi^{-1}(\beta) = z_\beta$$

$$e \geq (z_{1-\alpha} - z_\beta) \sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}} = (z_{1-\alpha} + z_{1-\beta}) \sqrt{\frac{S_Y^2}{m} + \frac{S_X^2}{n}}$$

Аналогично для двусторонней альтернативы

Также для связанных выборок можно доказать аналогичную теорему

Минимальное количество данных

Узнав эффект, можно получить необходимое количество данных для теста:

Пусть $m = n$

① при односторонней альтернативе

$$n \geq \frac{(z_{1-\alpha} + z_{1-\beta})^2 (S_X^2 + S_Y^2)}{e^2}$$

② при двусторонней альтернативе

$$n \geq \frac{(z_{1-\frac{\alpha}{2}} + z_{1-\beta})^2 (S_X^2 + S_Y^2)}{e^2}$$

Вывод

Чтобы уменьшить необходимое количество данных, нужно снижать дисперсию метрики

- 1 Введение
- 2 АБ-тест
- 3 MDE
- 4 **Снижение дисперсии**
- 5 Метрики

Стратификация

- 1 $Y_{1,1}, \dots, Y_{1,n_1}, \dots, Y_{K,n_K}$ - метрика
- 2 Y_k - k-я страта
- 3 n_k - количество элементов в k-й страте
- 4 $p_k = \frac{n_k}{n}$ - доля k-й страты
- 5 $\bar{Y}_k = \sum_{j=1}^{n_k} Y_{k,j}$ - среднее в k-й страте
- 6 $\mu = \mathbb{E}Y$
- 7 $\mu_k = \mathbb{E}Y_k$
- 8 $\sigma^2 = \mathbb{V}Y$
- 9 $\sigma_k^2 = \mathbb{V}Y_k$

Определение средних

- 1 $\bar{Y} = \frac{1}{n} \sum_{k=1}^K \sum_{j=1}^{n_k} Y_{k,j}$ - обычное среднее
- 2 $\bar{Y}_{strat} = \sum_{k=1}^K p_k \bar{Y}_k$ - стратифицированное среднее

Стратификация

Вместо обычного случайного семплирования можно брать данные для эксперимента так, чтобы доля каждой страты была такой же как и в изначальных данных (то откуда семплируем)

Утверждение (Равенство среднего и стратифицированного среднего)

При стратифицированном семплировании

$$\bar{Y} = \bar{Y}_{strat}$$

Утверждение (Несмещённость стратифицированного среднего при стратифицированном семплировании)

$$\mathbb{E}_{strat} \bar{Y}_{strat} = \mu = \mathbb{E} \bar{Y}$$

Доказательства всех утверждений со стратификацией можно найти в [AX16]

Стратификация

Утверждение (Уменьшение дисперсии при стратификации)

$$\textcircled{1} \mathbb{V}\bar{Y} = \frac{1}{n} \sum_{k=1}^K p_k \sigma_k^2 + \frac{1}{n} \sum_{k=1}^K p_k (\mu_k - \mu)^2$$

- обычное усреднение

$$\textcircled{2} \mathbb{V}\bar{Y}_{strat} = \frac{1}{n} \sum_{k=1}^K p_k \sigma_k^2 + \frac{1}{n^2} \sum_{k=1}^K (1 - p_k) \sigma_k^2 + O\left(\frac{1}{n^2}\right)$$

- постстратификация

$$\textcircled{3} \mathbb{V}_{strat} \bar{Y}_{strat} = \frac{1}{n} \sum_{k=1}^K p_k \sigma_k^2$$

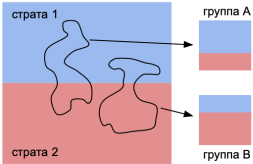
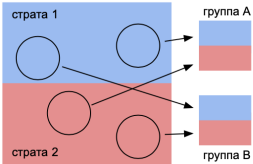
- стратификация

При этом

$$\mathbb{V}_{strat} \bar{Y}_{strat} = \mathbb{V}\bar{Y}_{strat} + O\left(\frac{1}{n^2}\right) = \mathbb{V}\bar{Y} + O\left(\frac{1}{n}\right)$$

$$\mathbb{V}_{strat} \bar{Y}_{strat} \leq \mathbb{V}\bar{Y}_{strat} \leq \mathbb{V}\bar{Y}$$

Стратификация

	Обычное среднее $\bar{Y} = \frac{1}{n} \sum_{k=1}^K \sum_{j=1}^{n_k} Y_{kj}$	Стратифицированное среднее $\hat{Y}_{strat} = \sum_{k=1}^K w_k \bar{Y}_k$
Случайное семплирование 	Классический подход Без стратификации	Постстратификация
Стратифицированное семплирование 	Не контролирует вероятность ошибки I рода	Стратификация

CUPED

Controlled-experiment Using Pre-Experiment Data - CUPED

- 1 Y - метрика
- 2 X - ковариата (коррелирующая с метрикой величина, не затронутая изменением (которое мы применяем к тестовой выборке))

$$Y_{CUPED} = Y - \theta X + \theta \mathbb{E}X$$

Утверждение (лучший выбор θ) [Den+13]

При $\theta = \frac{\text{cov}(X, Y)}{\mathbb{V}X}$ достигается

$$\min(\mathbb{V}\bar{Y}_{CUPED}) = \mathbb{V}\bar{Y} \left(1 - \left(\frac{\text{cov}(X, Y)}{\sqrt{\mathbb{V}X\mathbb{V}Y}} \right)^2 \right) = \mathbb{V}\bar{Y}(1 - \text{corr}^2(X, Y))$$

Вариации CUPED

CUPAC (Control Using Predictions as Covariate)

X - предсказание метрики ML моделью

$$Y_{CUPAC} = Y - \theta X + \theta \mathbb{E}X$$

CUMPED (Controlled-experiment Using Multiple Pre-Experiment Data)

X^1, \dots, X^m - ковариаты

$$Z_{CUMPED}^1 = Y - \theta_1 X^1 + \theta_1 \mathbb{E}X^1$$

$$Z_{CUMPED}^2 = Z_{CUMPED}^1 - \theta_2 X^2 + \theta_2 \mathbb{E}X^2$$

...

$$Z_{CUMPED}^m = Z_{CUMPED}^{m-1} - \theta_m X^m + \theta_m \mathbb{E}X^m$$

Несколько ковариат в CUPED

Несколько ковариат в CUPED

- X_1, X_2, \dots, X_k - ковариаты
- $\Sigma = \text{cov}(X_1, X_2, \dots, X_k)$
- $Z = \begin{pmatrix} \text{cov}(Y, X_1) \\ \dots \\ \text{cov}(Y, X_k) \end{pmatrix}$

Тогда при преобразовании $Y_{MultiCUPED} = Y - \sum_{i=1}^k \theta_i (X_i - \mathbb{E}X_i)$ минимальная дисперсия достигается на

$$\theta = \Sigma^{-1}Z$$

Связь CUPED и стратификации

Связь CUPED и стратификации [Den+13]

- 1 $\bar{Y}_{strat} = \sum_{i=1}^k p_i \bar{Y}_i$ - стратифицированное среднее
- 2 X_i - бинарная переменная о принадлежности к страте, $p_i = \mathbb{E}X_i$
- 3 $\bar{Y}_{CUPED} = \bar{Y} - \sum_{i=1}^k \theta_i (\bar{X}_i - p_i)$ - CUPED

Тогда

$$\bar{Y}_{CUPED} = \bar{Y}_{strat}$$

- 1 Введение
- 2 АБ-тест
- 3 MDE
- 4 Снижение дисперсии
- 5 Метрики**

Метрики

U - объекты

- Средние

$$M(U) = \frac{\sum_{u \in U} F(u)}{\sum_{u \in U} 1} = \frac{\sum_{u \in U} F(u)}{|U|}$$

- Ratio-метрики

$$M(U) = \frac{\sum_{u \in U} F(u)}{\sum_{u \in U} G(u)}$$

Ratio-метрики

Предусреднение

Усреднить метрику вида $\frac{\sum_{u \in U} \frac{F(u)}{G(u)}}{|U|}$ некорректно, т.к. эффект может носить свойство разнонаправленности




Рис. 3: Разнонаправленность, <https://habr.com/ru/companies/kuper/articles/768826/>

Ratio-метрики

Дисперсия ratio [Sel]

Пусть F, G - случайные величины, тогда

$$V \frac{F}{G} \approx \frac{(EF)^2}{(EG)^2} \left(\frac{VF}{(EF)^2} - 2 \frac{\text{cov}(F, G)}{EFEG} + \frac{VG}{(EG)^2} \right)$$

Дельта-метод

- 1 $X_1, \dots, X_n, Y_1, \dots, Y_n$ - независимые выборки,
- 2 M_{ratio} - ratio-метрика
- 3 $V_{ratio}(X)$ - оценка дисперсии для отношения

Тогда

$$\frac{M_{ratio}(Y) - M_{ratio}(X)}{\sqrt{\frac{V_{ratio}(Y)}{m} + \frac{V_{ratio}(X)}{n}}} \xrightarrow{d_0} \mathcal{N}(0, 1)$$

Ratio-метрики

Линеаризация [Bud+18]

① $X = X_A \cup X_B, Y = Y_A \cup Y_B,$

② $M_{ratio}(U) = \frac{\sum_{u \in U} X(u)}{\sum_{u \in U} Y(u)}$ - ratio-метрика

③ $I(u) = X(u) - Y(u)M_{ratio}(X_A), (M_{ratio}(X_A) - \text{значение метрики в контрольной группе})$

④ $L(U) = \{I(u) | u \in U\}, \bar{L}(U) = \frac{\sum_{u \in U} I(u)}{|U|}$

⑤ $T(L) = \frac{\bar{L}(B) - \bar{L}(A)}{\sqrt{\frac{S_{L(B)}^2}{m} + \frac{S_{L(A)}^2}{n}}}, D(M_{ratio}) = \frac{M_{ratio}(B) - M_{ratio}(A)}{\sqrt{\frac{V_{ratio}(B)}{m} + \frac{V_{ratio}(A)}{n}}}$

Тогда

Ratio-метрики

Линеаризация [Bud+18]

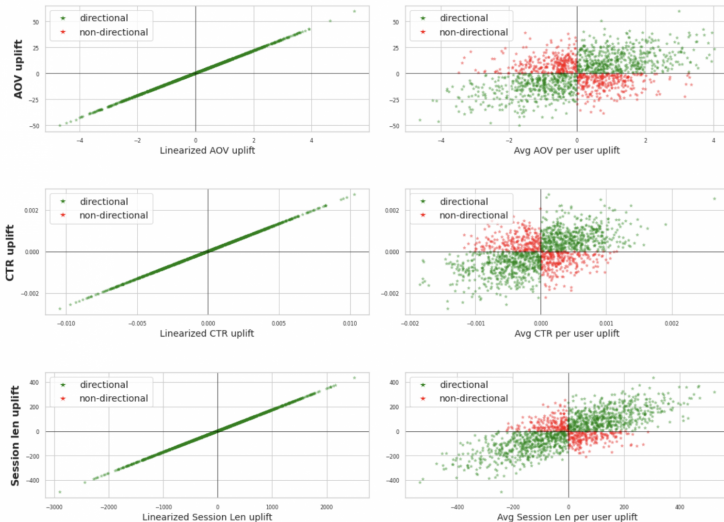
① для некоторого γ

$$T(L) = D(M_{ratio}) \sqrt{1 - \frac{\gamma}{\frac{V_{ratio}(B)}{m} + \frac{V_{ratio}(A)}{n} + \gamma}}$$

- ② Если $|\widehat{corr}_B(X, Y)| < c < 1$, то $\exists C_1(c), C_2(c), \varepsilon_1(c), \varepsilon_2(c)$ т.ч. $\left| \frac{\bar{X}_B - \bar{X}_A}{\bar{X}_B} \right| < \varepsilon_1(c)$ и $\left| \frac{\bar{Y}_B - \bar{Y}_A}{\bar{Y}_B} \right| < \varepsilon_2(c)$ и $\left| \frac{T(L)}{D(M_{ratio})} - 1 \right| \leq C_1(c) \left| \frac{\bar{X}_B - \bar{X}_A}{\bar{X}_B} \right| + C_2(c) \left| \frac{\bar{Y}_B - \bar{Y}_A}{\bar{Y}_B} \right|$
- ③ Если $|corr(X, Y|B)| < c < 1$, $\mathbb{E}(X|A) \neq 0$, $\mathbb{E}(Y|A) \neq 0$, то

$$T(L) \xrightarrow{d_0} \mathcal{N}(0, 1)$$

Ratio-метрики



Литература

- [Den+13] Alex Deng и др. «Improving the Sensitivity of Online Controlled Experiments by Utilizing Pre-Experiment Data». В: (2013). URL: <https://exp-platform.com/Documents/2013-02-CUPED-ImprovingSensitivityOfControlledExperiments.pdf>.
- [AX16] Juliette Aurisset и Huizhi Xie. «Improving the Sensitivity of Online Controlled Experiments: Case Studies at Netflix». В: (2016). URL: <https://www.kdd.org/kdd2016/papers/files/adp0945-xieA.pdf>.
- [Bud+18] Roman Budylin и др. «Consistent Transformation of Ratio Metrics for Efficient Online Controlled Experiments». В: (2018). URL: https://www.researchgate.net/publication/322969314_Consistent_Transformation_of_Ratio_Metrics_for_Efficient_Online_Controlled_Experiments#fullTextFileContent.
- [Sel] Howard Seltman. «Approximations for Mean and Variance of a Ratio». В: (). URL: <https://www.stat.cmu.edu/~hseltman/files/ratio.pdf>.

Всё !

Иван Новиков

ivannovikov1303@gmail.com